

# 上海大学 2023 ~ 2024 学年 课程报告成绩评价表

课程名称： 《模式识别》 课程编号： 08306089

报告名称：

基于深度学习的颈部淋巴结转移性预测方法

姓 名： 王子棠 学 号： 21122897

报告评语：

--

报告成绩：

方案设计（20 分）		验收（20 分）		书面报告（60 分）			2* 总分
可行性 (10 分)	创新性 (10 分)	规范性 (10 分)	演示效果 (10 分)	规范性 (20 分)	完整性 (20 分)	科学性 (20 分)	

任课教师：

评阅日期：        年        月        日

# 基于深度学习的颈部淋巴结转移性预测方法

王子棠 (21122897)

**摘要：**颈部淋巴结疾病已经对人类身体健康造成了严重危害，其中颈部淋巴结转移与否的术前评估对甲状腺癌的治疗至关重要。目前的常规颈部超声检查存在诊断主观性强、准确率较低等问题。为了提高淋巴结的标准化诊断，设计了一种基于定位和分类网络的淋巴结转移性预测方法。通过先定位淋巴结位置并提取特征，再对良恶性进行分类来预测转移性，相比于常规超声检查，准确率提高了 8.5%，说明该方法可以有效辅助医生进行诊断。

## 1 引言

### 1.1 提出问题

甲状腺结节是一种常见疾病，发病率高达 32.4%，而甲状腺癌会引起颈部淋巴结转移。颈部中央淋巴结转移与乳头状甲状腺癌恶化程度息息相关，淋巴结转移与否的正确诊断对甲状腺癌的治疗至关重要。诊断颈部淋巴结转移性可以确定乳头状甲状腺癌的恶化程度，也有助于制定最佳的手术治疗方案 [1]。目前常规的颈部超声检查流程是在使用高频探头扫描确定的颈部淋巴结区域后，根据淋巴结影像学特征进行分析判断其转移性，最后得到淋巴结诊断报 [2]。对于超声中可疑的淋巴结还需要进一步通过细针穿刺活检。然而，常规诊断流程存在几点问题。第一，基层超声科医生严重不足，且临床经验不足，一般难以解读颈部超声图上的信息。第二，对于超声科医生来说，颈部淋巴结的超声评估没有普遍适用的诊断标准，由于医生经验的差别以及他们的主观性可能造成诊断准确性的差别，进一步导致诊断报告质量的参差不齐，临床上也急需更稳健的方法改进诊断策略。

由于淋巴结有形态小、不规则、分布区域广、个体形状差异大、易受血管等相似组织干扰等特征，以及网上缺少针对超声淋巴结的公开数据集，目前基于深度学习的颈部淋巴结超声影像相关研究的转移性预测结果并不理想。因此联合分类和定位网络对淋巴结进行识别是本文的研究重点。

### 1.2 求解方案分析

针对颈部淋巴结诊断流程中存在的问题，在导师的带领下获得了上海市第六人民医院的颈部淋巴结转移性相关超声数据集支持，共 1108 张淋巴结超声图像，其中良性 524 张，恶性 584 张。数据集获得上海市第六人民医院伦理委员会的批准（编号：SH6H-2021-YS-218）。

大部分已有的基于深度学习研究淋巴结转移性相关研究使用的都是分割网络或分类网络直接对颈部淋巴结进行分析。根据研究表明，淋巴结边界结构的清晰度与诊断有关，这需要对边界和边界外的少数像素区域进行比较分析，对淋巴结分割可能会损失边界相关特征。并且，淋巴结形态小，分布区域广，与血管组织相似，在淋巴结超声图像分类过程中容易收到淋巴结周围组织以及相似组织的干扰。因此研究中在对淋巴结进行分类之前引入目标检

测算法对淋巴结进行定位和裁剪，这样可以去除无关的超声背景区域，而且还保留了与淋巴结边界相关的信息。先定位后分类的解决方法可以有效减少噪声区域，提供分类所需的淋巴结特征。该方法的准确率相比于常规超声检查提高了 8.5%，阳性预测值提高了 15.9%[3]。

### 1.3 论文概述

本文以模式识别课堂中学习的深度学习相关内容为基础展开，研究深度学习在医学领域的应用，论文共分为六个部分。第一部分介绍了超声图像中颈部淋巴结诊断的背景意义以及目前诊断存在的不足之处。第二部分介绍预测淋巴结转移性使用的定位和分类算法的相关内容。第三部分介绍具体的网络框架以及具体算法流程。第四部分介绍具体预测的实验步骤以及实验结果。第五部分和第六部分对结论、进一步的研究方向以及学习体会和建议进行阐述。

## 2 相关算法概述

### 2.1 YOLOv5s 定位网络

YOLOv5[4] 是一种基于深度学习的物体检测方法,具有高效、高精度等特点。其中,YOLOv5s 相对来说计算量较小、速度较快。

YOLOv5s 的 backbone 使用了较为新颖的 SPP(Spatial Pyramid Pooling) 模块。相较于其他物体检测算法中的 backbone (如 ResNet、DarkNet 等), SPP 可以将多种大小的特征图组合在一起,生成一个全局的特征描述,因此对于小物体、遮挡、光照等问题有较强的鲁棒性。SPP 模块的通道数量是其入口的四倍。

YOLOv5s 的 Head 主要包含三个部分: FPN、PAN 和 YOLO Detection 层。其中, FPN 是一种特征金字塔网络模型,负责提取特征图中的更加抽象的特征,以便更好地进行目标分类和检测。PAN 是一种路径聚合模型,主要用于调整不同特征金字塔之间的大小和通道数,使其能够适应不同大小的目标检测。而 YOLO Detection 层是一个检测层,主要负责计算边界框的坐标值、置信度以及类别概率值。

YOLOv5s 的 Neck 是一个由 CSP 模块、SPP 模块和 PAN 模块附加而来的部分,其主要功能是信息的优化和整合。CSP 模块是一种含多层卷积的模块化架构,其主要思想是将相邻卷积层的通道数量分成两部分进行计算,增加了模型的复杂性,但也保证了模型的稳定性。PAN 模块主要是针对高层次和低层次的特征图之间的边界问题,采用了双线性插值和上下采样来调整特征图的 size。算法流程如图1所示。



图 1: YOLOv5s 算法流程图

## 2.2 ConvNeXt 分类网络

为了进一步改善 CNN 全局特征提取能力, ConvNeXt 在 ResNet 模型的基础上, 仿照 Swin Transformer 的结构进行改进得到纯卷积模型。ConvNeXt 纯卷积神经网络是由 Facebook AI Research 和 UC Berkeley 提出的, 它对标的是 Swin Transformer, 通过一系列实验比对, 在相同的 FLOPs 下, ConvNeXt 相比 Swin Transformer 拥有更快的推理速度以及更高的准确率。[5]

ConvNeXt 采用了密集连接和组卷积的思想。这种设计可以提高模型的感受野, 同时减少参数数量。具体而言, ConvNeXt 将多个不同尺寸的卷积核组合成一个大的卷积核。这种方法比传统的卷积核更加灵活, 能够捕获更多的局部特征。原理结构如图2所示。

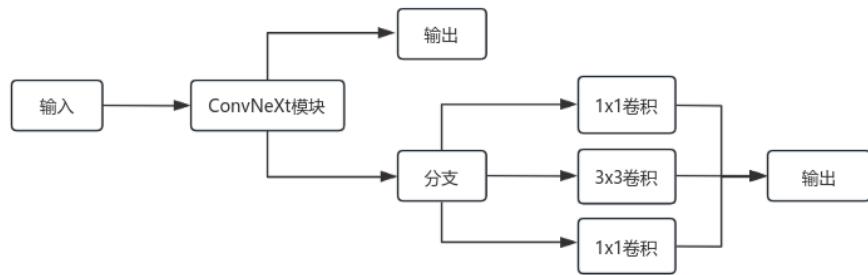


图 2: ConvNeXt 原理结构图

ConvNext 做了如下改进: 通过调整 ResNet50 的 stage 计算比例、修改 stem 结构和参考 ResNeXt 的设计, 将普通卷积替换为深度可分离卷积, 该卷积与自注意力计算中加权求和的操作相似, 降低了计算量; 将通道数进行调整与 Swin Transformer 保持一致, 使准确率提升; 采用了 GELU 替换 ReLU、减少激活函数、替换 BN 为 LN 以及分离下采样层等方法, 进一步提升了性能, 最终在图像分类任务中取得了显著的准确率提升, 突破了 Swin-T 的效果。

## 3 算法实现描述

为了提高颈部淋巴结转移性预测的准确率和效率, 提出了一个联合定位和分类的网络架构。该架构由两个网络模型组成: 一个是识别淋巴结的 YOLOv5s 定位网络, 一个是由 ConvNet 模块构建的用于分类的 ConvNeXt 卷积神经网络。定位网络识别出淋巴结区域并将淋巴结区域截取出来, 保留淋巴结及其边界结构相关的特征, 接着利用分类网络对超声图像进行分析, 提取到具有区分性的转移性特征, 通过分类器和 Softmax 计算得到预测结果。该方法可以较为准确地预测出淋巴结转移性, 为医生和学者的辅助诊断提供帮助。

### 3.1 数据预处理

超声图像是直接来自超声系统中采集出来的, 图像里含有设备界面区域, 且存在设备界面标记和十字标记, 与淋巴结分类任务无关。因此需要先把超声区域截取出来, 接着使用十字标记去除算法, 去除淋巴结区域的十字标记。随后, 对处理好的数据进行数据增强, 并

采用自适应阈值直方图均衡化 CLAHE 算法来调整超声对比度，然后将超声像素值归一化，最后转换为  $224 \times 224$  像素大小。

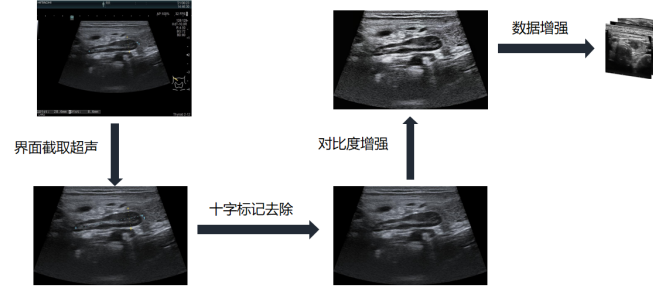


图 3: 数据预处理流程图

#### Algorithm 1 十字标记去除算法步骤

**Input:** 截取出超声区域后的淋巴结超声图像;

**Output:** 去除十字标记后的超声图像;

- 1: 加载数据;
- 2: 识别超声区域中的黑色像素值;
- 3: 使用 OpenCV 中形态学开运算的 morphologyEx 函数，去除噪声;
- 4: 使用 OpenCV 的 FindContours 函数，识别出图像中的封闭区域（淋巴结等类似结构）;
- 5: 对封闭区域填充黑色像素值后使用形态学闭运算去除噪声;
- 6: 将图像进行取反操作，筛选十字标记区域;
- 7: 使用 OpenCV 中的 Inpaint 函数对十字标记进行消除;

### 3.2 算法总体框架

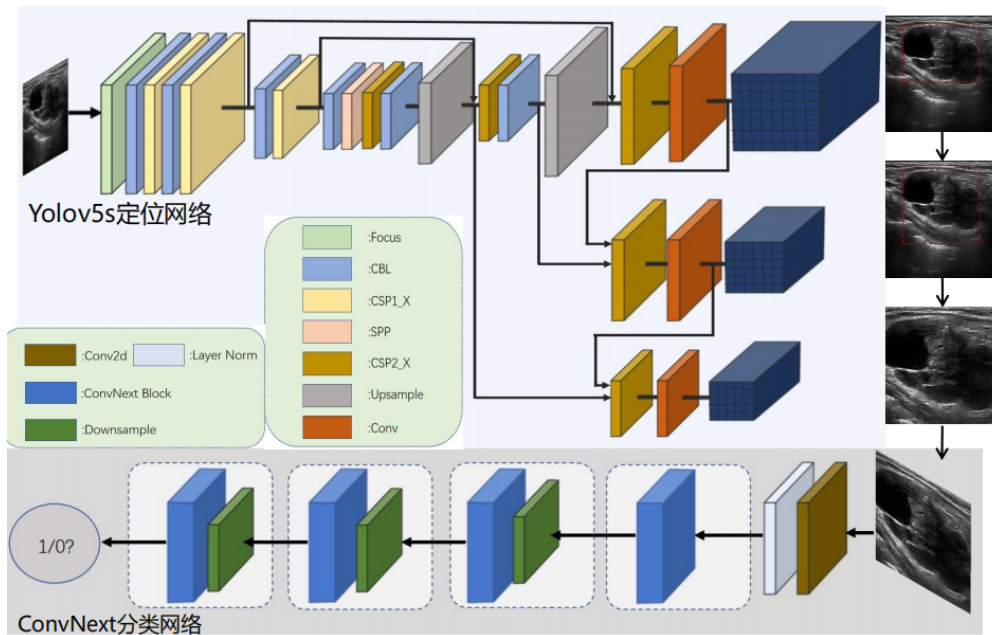


图 4: 定位分类联合网络架构图

针对淋巴结分布广、不规则、大小差异大，容易受血管等相似组织干扰而导致不易于分析与预测的特点，设计了一个联合定位网络和分类网络的淋巴结转移性预测框架。总体框架如图4所示。整体的框架分为基于 Yolov5s 的定位网络以及基于 ConvNeXt 的分类网络，首先输入一张完整的超声图像进入定位网络，通过定位网络将输出一张包含定位框的淋巴结超声图并按定位框坐标信息截取超声图，接着把截取后的超声图输入分类网络中，将得到分类结果，包含淋巴结是良性的概率以及淋巴结是恶性的概率。架构中最后输出的 1 代表恶性，0 代表良性。先通过定位网络可以去除与淋巴结无关的背景区域与血管、肌肉等组织，使分类网络专注于淋巴结周边和内部区域中转移性特征相关的分类信息。

算法总体思路是“先定位后分类”，这样可以免除只对淋巴结进行分割或者分类带来的可能损失边界结构信息的弊端，有助于模型在面对各种目标形状和尺寸的情况下更好地泛化。并且，可以减少误检率，减少背景区域以及相似结构的组织的干扰，大大减少了计算的复杂性，提高了检测的效率。Yolov5s 与 ConvNeXt 的结合使得预测任务更加灵活，适用于需要精确定位和难以识别的目标，这样的架构可以充分利用 YOLOv5s 的快速定位能力，同时通过 ConvNeXt 实现对目标进行更精细的分类。

### 3.3 Yolov5s 改进

淋巴结超声图像经预处理算法处理后首先输入到 Yolov5s 定位网络，对淋巴结进行定位和识别。定位网络输出三个不同大小的特征图，其中越大的特征图用于检测越小的目标。由定位网络得到淋巴结所在定位框的坐标信息，根据定位框的最大边长得到方形框，裁剪淋巴结超声图像，并压缩至  $224 \times 224$  像素大小，再将处理后的超声图像放入分类网络中训练。这里的图像裁剪压缩算法嵌入在定位部分，实现端到端和联合训练。

将训练模型的图像设定为  $\text{Img} \in \mathbb{R}^{C \times H \times W}$ ，其中 C,H,W 分别是输入图像的通道数、高度和宽度。Img 输入到 Yolov5s 定位网络中，定位网络的结构如图4所示。除了预先设置的锚框之外，还根据数据集中的注释信息自适应地调整锚框，并设置一个先验 IoU 阈值 ( $\geq 0.2$ )。该模块由来自 Yolov5 的 Focus、CBL、CSP、SPP、Upsample 子模块和单卷积层组成。不同尺度的特征图计算公式如式1-3所示：

$$F_1^{\text{loc}} = \text{Focus}(\text{CBL}(\text{CSP1\_1}(\text{CBL}(\text{CSP1\_3}(\text{Img})))) \quad (1)$$

$$F_2^{\text{loc}} = \text{CBL}(\text{CSP1\_3}(F_1^{\text{loc}})) \quad (2)$$

$$F_3^{\text{loc}} = \text{CBL}(\text{SPP}(\text{CSP2\_1}(\text{CBL}(F_2^{\text{loc}})))) \quad (3)$$

除此之外，还在 Yolov5s 中加入 SE 模块 [6]，可以让网络更加关注淋巴结，提高检测效果。

## 4 实验描述

### 4.1 实验数据和实验方案

实验所使用的颈部淋巴结超声数据集收集来自于上海市第六人民医院超声科 2020 年 10 月至 2022 年 12 月期间真实患者的数据，共 1108 张淋巴结超声图像。分类标注以医生提供的病理学报告为依据，其中良性 524 张，恶性 584 张。定位标注由专家进行。该数据由上海市第六人民医院超声科进行的常规超声检查中获得。超声图像主要由西门子超声系

统完成采集。本实验将数据按照 6:2:2 的比例划分为训练集、验证集和测试集，数据经过对比度增强等数据预处理方法后训练模型。数据分布情况如表1所示。

表 1: 颈部淋巴结数据集分布情况

类别	数据总量
Benign	524
Malignant	584
All	1108

整体架构由两个网络组成，因此分别对两个网络进行训练。先使用原始的颈部淋巴结超声图像作为数据集对定位网络进行训练，接着利用训练好的定位网络输出根据方形框裁剪的超声图像，这一部分作为分类网络的数据集。由于样本量比较小，在分类网络中加入了数据增强，随机旋转、翻转图像来增加样本多样性。训练过程中 batchsize 设置为 8，epoch 设置为 50。训练完毕后整合两个网络，做到联合预测，即输入一张颈部淋巴结超声图像后会先经过定位网络输出一张定位到淋巴结的包含定位框的图像，接着通过分类网络输出淋巴结的良恶性以及相应概率至 txt 文件中，若恶性概率 (m) 比良性概率 (b) 大，那么说明该淋巴结转移。具体流程如图5所示。




图 5: 联合预测流程图

## 4.2 评价指标及结果分析

实验中常用的分类任务中常见的分类指标: 准确率 (Accuracy, ACC)、精确率 (Positive Predictive Value, PPV)、真阳性率 (True Positive Rate, TPR)、真阴性率 (True Negative Rate, TNR)、F1 (F1-Score)、ROC 曲线下面积 (Area Under Curve, AUC)。ACC 用于评估颈部淋巴结超声转移性预测的整体准确性，即预测正确的样本数量占总量的百分比。PPV 是指模型预测的转移性样本中判断正确的比例。TPR 是指判断正确的转移性样本数占总转移性样本数的比例，用于评估对于整体转移性类别数据中的分类状况。TNR 是指判断正确的非转移性样本数占总非转移性样本数的比例，用于评估对于整体非转移性类别数据中的分类状况。F1 综合考虑精确率和召回率。AUC 表示 ROC 曲线下用坐标轴围成的面积，面积越大越好。这是一个二分类任务，在这里淋巴结分为两类：恶性和良性，其中恶性作为阳性，良性作为阴性，若恶性概率大则淋巴结转移。指标计算公式如式4-8所示。

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

$$PPV = \frac{TP}{TP + FP} \quad (5)$$



$$TPR = \frac{TP}{TP + FN} \quad (6)$$

$$TNR = \frac{TN}{TN + FP} \quad (7)$$

$$textF1 = \frac{2 \times PPV \times TPR}{PPV + TPR} \quad (8)$$

实验结果如表2所示,可以看出改进后的 Yolov5s 与 ConvNeXt 联合的架构预测转移性效果更好。

表 2: 整体架构对比实验结果

模型名	ACC	PPV	TPR	TNR	F1	AUC
Yolov5s+ConvNeXtTiny[5]	0.719	0.728	0.762	0.685	0.744	0.70
Our model	<b>0.737</b>	0.710	<b>0.826</b>	0.642	<b>0.763</b>	<b>0.81</b>

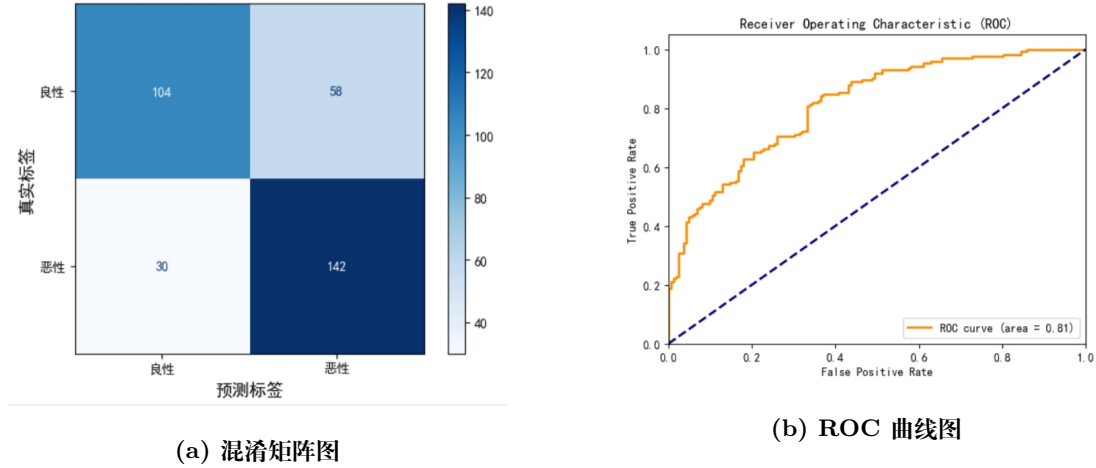


图 6: 实验评价指标图

## 5 结论

针对颈部淋巴结超声诊断中存在医生主观经验强、诊断准确率较低等问题,研究了颈部淋巴结转移性预测方法。由于淋巴结超声公开数据集较少、淋巴结差异大、与血管等组织相似,研究获得上海市第六人民医院的数据集支持,数据集由医生和专家进行标注,并设计了一个联合预测的方法,整体架构分为定位和分类网络,定位到淋巴结后再进行分类可以去除与淋巴结无关的背景区域,提高分类准确率。对 Yolov5s 进行改进,在其中加入 SE 注意力机制,提高检测能力。根据改进前与改进后的实验结果对比,可以发现在 ACC,TPR,F1 和 AUC 这四个指标上效果有所提升。

总结来说,本文实现了颈部淋巴结超声诊断流程中的关键步骤,并实现了转移性诊断的自动化,可以辅助医生治疗,提高诊断效率,为医生的诊断提供参考,并且可以降低医生的主观经验影响,推动超声智能诊断治疗的规范化与标准化。

但实验还存在着改进空间。由于模型缺乏解释性,未来可以生成与模型相关的热力图,来观察转移性区域,帮助医生理解模型决策,增加模型的可靠性。并且还可以对分类网络进



行改进，如增加频域注意力等机制，提高分类的准确率。该实验是针对静态的超声图进行预测，在实际诊断中，医生都是利用超声设备动态对超声图进行观察与分析，后续可以考虑研究动态超声视频中淋巴结转移性的分析方法。

## 6 学习体会和建议

在完成这次模式识别的项目的过程中，我意识到了面对医学图像的特定挑战，包括类别不平衡、数据标注的困难等，这对模型的设计和训练提出了额外的要求。我学习到了对医学数据集的预处理方法以及数据增强的方法，有助于增加样本多样性，提高模型的泛化能力。并且，深入学习了近几年热门的定位和分类网络的架构，并尝试改进这些网络。通过定位和分类网络的联合使用，模型可以更全面地理解淋巴结的特征，这种联合预测的方法对于解决目标在图像中复杂位置的问题具有显著的优势。

需要注意的是，在医学应用中，模型的解释和可解释性是至关重要的。后续可以考虑使用解释性技术，如 Grad-CAM 等，用来可视化模型对淋巴结转移的关注区域。通过这次项目经历，我深入了解了医学图像分析的挑战和机遇，期待在未来的学习和工作中进一步探索人工智能与医疗相结合的领域。

## 参考文献

- [1] Sung H, Ferlay J, Siegel R L, et al. Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries[J]. *CA: a cancer journal for clinicians*, 2021, 71(3): 209-249.
- [2] Liu S, Wang Y, Yang X, et al. Deep learning in medical ultrasound analysis: a review[J]. *Engineering*, 2019, 5(2): 261-275.
- [3] 刘娜香, 唐丽娜, 王瑶琴, 等. 超声造影在侧颈部淋巴结良恶性鉴别诊断中的价值. *中华医学杂志*, 2020, 100(29): 2258-2262. DOI: 10.3760/cma.j.cn112137-20200221-00390.
- [4] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [5] Liu Z, Mao H, Wu C Y, et al. A convnet for the 2020s[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11976-11986.
- [6] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[J]. *arXiv preprint arXiv:1709.01507*, 2017, 7.

## 附件 1：自学报告讲义

<h2>04 基于华为平台的Bert应用-理论</h2> <p>21122897 王子豪</p>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>1.文本纠错</h4> <ul style="list-style-type: none"> <li>文本纠错，是指自动识别文档错误，将错误文本修正为正确文本的过程。一般指对文本中的错别字、语法错误、拼写错误等进行修正。</li> <li>常见的文本纠错可以分为： <ul style="list-style-type: none"> <li>基于规则的方法：通过预定义的规则，对文本中的错误进行识别和修正。</li> <li>基于机器学习的方法：通过训练模型，对文本中的错误进行识别和修正。</li> </ul> </li> <li>基于机器学习的文本纠错模型，其核心思想是利用深度学习模型，对文本中的错误进行识别和修正。这类模型通常需要将文本转换为向量表示，然后通过模型进行预测和修正。</li> <li>基于bert的文本纠错模型，其核心思想是利用bert模型强大的语义理解能力，对文本中的错误进行识别和修正。这类模型通常需要将文本转换为bert模型的输入格式，然后通过模型进行预测和修正。</li> </ul>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>2.SIGHAN数据集</h4> <p>SIGHAN数据集是由台湾大学开发的用于中文文本纠错（CSC）任务的数据集。该数据集包含三个版本：SIGHAN 2005、SIGHAN 2006 和 SIGHAN 2009。每个版本都包含训练集、开发集和测试集。</p> <table border="1"> <thead> <tr> <th>版本</th> <th>训练集</th> <th>开发集</th> <th>测试集</th> </tr> </thead> <tbody> <tr> <td>SIGHAN 2005</td> <td>10000</td> <td>1000</td> <td>1000</td> </tr> <tr> <td>SIGHAN 2006</td> <td>10000</td> <td>1000</td> <td>1000</td> </tr> <tr> <td>SIGHAN 2009</td> <td>10000</td> <td>1000</td> <td>1000</td> </tr> </tbody> </table>	版本	训练集	开发集	测试集	SIGHAN 2005	10000	1000	1000	SIGHAN 2006	10000	1000	1000	SIGHAN 2009	10000	1000	1000
版本	训练集	开发集	测试集															
SIGHAN 2005	10000	1000	1000															
SIGHAN 2006	10000	1000	1000															
SIGHAN 2009	10000	1000	1000															
<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>2.1数据集预处理——训练集预处理</h4> <p>训练集预处理是文本纠错模型训练的关键步骤。对于SIGHAN数据集，预处理主要包括以下步骤：</p> <ol style="list-style-type: none"> <li>数据清洗：去除训练集中的无效数据和噪声。</li> <li>分词：将训练集中的文本按照词进行分词。</li> <li>词嵌入：将分词后的文本转换为词嵌入表示。</li> <li>数据增强：通过数据增强技术，增加训练集的数据量。</li> <li>数据集划分：将训练集划分为训练集、开发集和测试集。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>1.安装bert库为深度学习</h4> <p>安装bert库是构建基于bert的文本纠错模型的第一步。可以通过以下命令安装bert库：</p> <pre>pip install transformers</pre> <h4>2.使用bert库进行训练</h4> <p>使用bert库进行训练的关键步骤包括：</p> <ol style="list-style-type: none"> <li>加载训练数据：将训练集数据加载到bert模型中。</li> <li>模型训练：使用bert模型对训练数据进行训练。</li> <li>模型评估：使用开发集数据对训练好的模型进行评估。</li> <li>模型推理：使用测试集数据对训练好的模型进行推理。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>3.数据模型可读取的数据集格式</h4> <p>数据模型可读取的数据集格式是文本纠错模型训练的关键。对于SIGHAN数据集，数据集格式通常包括：</p> <ul style="list-style-type: none"> <li>训练集：包含训练数据的文本和对应的纠错标签。</li> <li>开发集：包含开发数据的文本和对应的纠错标签。</li> <li>测试集：包含测试数据的文本和对应的纠错标签。</li> </ul>																
<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>2.2数据集预处理——测试集预处理</h4> <p>测试集预处理是文本纠错模型训练的关键步骤。对于SIGHAN数据集，预处理主要包括以下步骤：</p> <ol style="list-style-type: none"> <li>数据清洗：去除测试集中的无效数据和噪声。</li> <li>分词：将测试集中的文本按照词进行分词。</li> <li>词嵌入：将分词后的文本转换为词嵌入表示。</li> <li>数据集划分：将测试集划分为训练集、开发集和测试集。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>3.检测网络</h4> <p>检测网络是文本纠错模型的核心部分。它负责检测文本中的错误，并将错误的文本修正为正确的文本。检测网络通常由以下部分组成：</p> <ul style="list-style-type: none"> <li>输入层：接收待检测的文本。</li> <li>特征提取层：提取文本的特征。</li> <li>检测层：检测文本中的错误。</li> <li>修正层：将错误的文本修正为正确的文本。</li> </ul>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>4.模型训练</h4> <p>模型训练是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>训练数据准备：将训练集数据加载到模型中。</li> <li>模型训练：使用训练数据对模型进行训练。</li> </ol>																
<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>3.Soft-Masked BERT模型</h4> <p>Soft-Masked BERT模型是文本纠错模型的一种。它基于bert模型，通过引入Soft-Masking机制，对文本中的错误进行识别和修正。Soft-Masking机制的核心思想是：在训练过程中，将文本中的某些词替换为特殊 token，然后在推理过程中，通过模型对这些特殊 token 进行预测，从而实现文本纠错。</p>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>4.模型训练</h4> <p>模型训练是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>训练数据准备：将训练集数据加载到模型中。</li> <li>模型训练：使用训练数据对模型进行训练。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>4.模型训练</h4> <p>模型训练是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>训练数据准备：将训练集数据加载到模型中。</li> <li>模型训练：使用训练数据对模型进行训练。</li> </ol>																
<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>2.纠错测试</h4> <p>纠错测试是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>测试数据准备：将测试集数据加载到模型中。</li> <li>模型推理：使用测试数据对模型进行推理。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>4.模型训练</h4> <p>模型训练是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>训练数据准备：将训练集数据加载到模型中。</li> <li>模型训练：使用训练数据对模型进行训练。</li> </ol>	<h3>基于bert的文本纠错模型：Soft-Masked bert</h3> <h4>4.模型训练</h4> <p>模型训练是文本纠错模型训练的关键步骤。它包括以下两个部分：</p> <ol style="list-style-type: none"> <li>训练数据准备：将训练集数据加载到模型中。</li> <li>模型训练：使用训练数据对模型进行训练。</li> </ol>																